[과제 4] 문장 유사도 계산을 워드 임베딩 기법 등 다양한 방법으로 구현

- 입력: 한글 문장 1개
- 방법: 형태소 분석기 2가지와 WPM, 총 3가지 이상의 방법으로 실험

가장 정확도가 높은, 가장 실행 속도가 빠른 방법이 무엇인지, 각 방법들의 장점과 단점, 문제점 및 해결방안은 무엇인지를 비교/실험

- 제출물: 소스코드 및 실행파일, 보고서(실행속도 및 실행화면 스샷 포함)
- 3~5분 내외 동영상 제작(유투브에 업로드) — 구현 방법 설명 및 실행 내용

  <참고1>

  입력문장과 말뭉치의 각 문장들을 워드 임베딩 기법 등을 이용하여 문장 벡터를 만들고, 벡터 유사도 계산 기법을 이용하는 방법을 추가한 경우 가산점을 부여함.

  <참고2>

  실행속도가 매우 빠른 새로운 방법을 사용하여 구현한 경우에 가산점을 부여함.

  멀티 쓰레딩 기법, DBMS 등 다양한 기법 사용 가능.

- 제출하는 모든 실습 및 과제의 소스 코드는 아래 GitHub 경로에 있습니다.
  `https://github.com/joshua-dev/bigdata`

실행 결과

- 모델 훈련

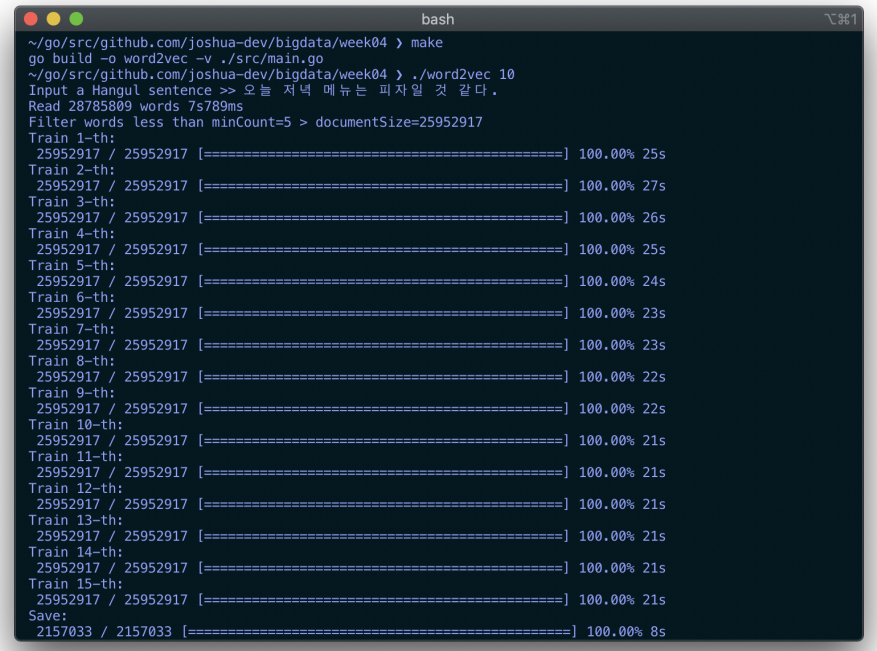

- 유사도 계산 및 실행 시간

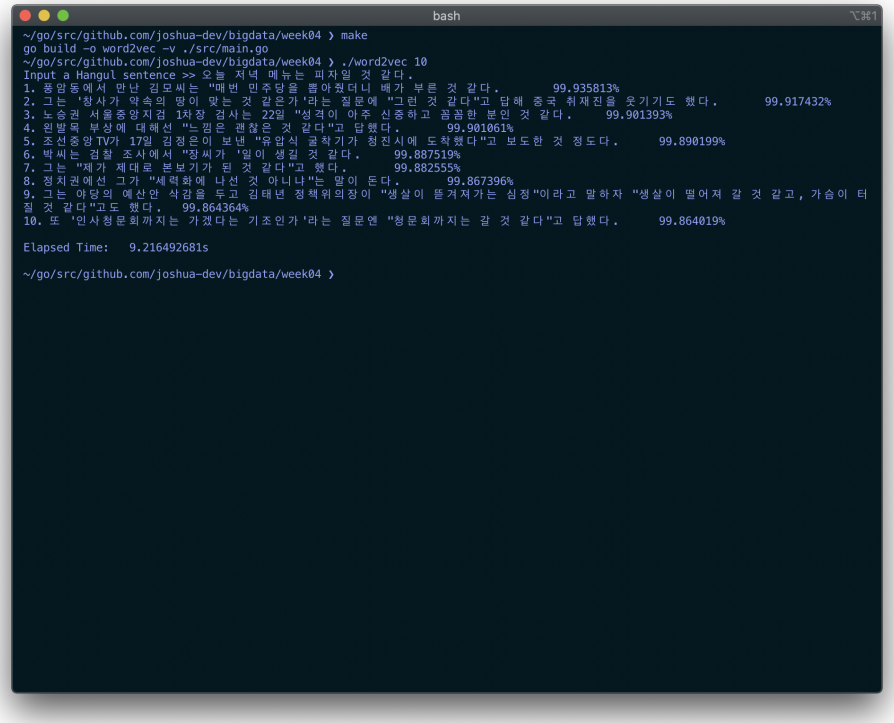

Installation

```
$ make install
```

Run

```
// n means the number of high similarity sentences to be printed.
// ex) ./word2vec 10
$ make
$ ./word2vec n
```

구현 방법 및 결과 분석

다음과 같은 순서로 워드 임베딩 기법을 사용한 문장 유사도 알고리즘을 만들었다.

모델의 학습 세대는 15회이고, 학습하는 데 걸리는 시간은 소요 시간에서 제외했다.

(각 세대 당 평균 학습 시간은 25초 내외이다.)

1. 사용자 입력 문장과 KCC 말뭉치로 워드 임베딩 구현체 중 word2vec 모델을 학습시키고 단어 벡터를 생성한다.
2. 시간 측정을 시작하고 생성된 단어 벡터를 로딩하여 자료구조에 저장한다.
3. KCC 말뭉치의 각 문장과 사용자 입력 문장을 `2` 의 단어 벡터를 사용하여 문장 벡터로 만들고 자료구조에 저장한다.
4. `3` 의 자료구조의 각 문장 벡터들과 사용자 입력 문장을 나타내는 문장 벡터를 고루틴 (goroutine) 을 이용한 멀티 쓰레딩 기법으로 빠르게 유사도를 계산하고 채널에 저장한다.
5. 최대 힙 (max heap) 을 생성하고 채널의 각 구조체에 접근하여 최대 힙에 push한다.
6. `5`의 최대 힙에서 `n` 번 pop하여 유사도가 가장 높은 상위 n개 문장을 출력하고 시간 측정을 종료한다.

구현 상세

1. word2vec

word2vec은 Google의 Mikolov 등이 개발한 CBOW 방식과 Skip-gram 방식의 워드 임베딩 구현체이다.

이 라이브러리는 기본적인 임베딩 모형에 subsampling, negative sampling 등의 기법을 추가하여 학습 속도를 향상시켰다.

이번 과제에서는 word2vec의 go 구현체인 wego (Word Embedding in Go) 라이브러리를 사용했다.

wego GitHub

wego는 다음과 같이 각 단어들을 벡터의 형태로 변환한다.

```
<word> <value1> <value2> ...
```

word2vec의 장점은 각 단어들이 가지는 의미를 보존하기 때문에, 아래와 같은 연산이 가능하다는 것이다.

```
Vector("King") - Vector("Man") + Vector("Woman") = Vector("Queen")
```

- wego를 이용해 KCC 말뭉치와 사용자 입력 문장을 학습시키는 train.go

```
// Train trains word vectors using wego APIs.
func Train(data, output string) error
```

2. 생성된 단어 벡터들을 로딩하여 map에 저장하는 main의 일부

```
vectors := make(map[string]vector.Vector)
outputFile, err := os.Open(outputData)
if err != nil {
  panic(err)
}

defer outputFile.Close()

scanner := bufio.NewScanner(outputFile)

for scanner.Scan() {
  txt := strings.Split(strings.TrimSpace(scanner.Text()), " ")
  word := txt[0]
  data := txt[1:]
  vector := vector.New(data)
  vectors[word] = vector
}
```

3. 2 의 단어 벡터들로부터 KCC 말뭉치와 입력 문장을 문장 벡터로 변환

단어 벡터로부터 문장 벡터를 생성하는 데에는 다양한 방법이 있다.

문장을 구성하는 단어의 단어 벡터를 단순히 더할 수도 있고, 각 단어들의 출현 빈도를 고려하여 가중치를 곱해서 더하는 SIF 방식도 있으며, RNN을 사용하여 가중치를 학습시키는 방법도 있다.

이 과제에서는 다음과 같이 각 문장을 구성하는 단어들의 단어 벡터를 더하는 방식으로 문장 벡터를 생성하였다.

```
// Word2Sent returns the average vector of the given vectors.
func Word2Sent(vectors []Vector) Vector
```

- KCC 말뭉치의 각 문장들을 문장 벡터로 변환하고 slice에 저장하는 main의 일부

```
var originVector vector.Vector

scanner = bufio.NewScanner(inputFile)

for scanner.Scan() {
  sentence := strings.TrimSpace(scanner.Text())
  words := strings.Split(sentence, " ")
  wordVectors := make([]vector.Vector, len(words))

  for index, word := range words {
  wordVectors[index] = vectors[word]
  }

  sentenceVector := vector.Word2Sent(wordVectors)

  if sentenceVector != nil {
    if sentence == origin {
      originVector = sentenceVector
    } else {
      temp := sentenceNvector{
      sentence: sentence,
      vector: sentenceVector,
      }
      sentenceNvectors = append(sentenceNvectors, temp)
    }
  }
}
```

4. KCC 말뭉치의 문장 벡터들과 입력 문장의 문장 벡터를 비교

- goroutine

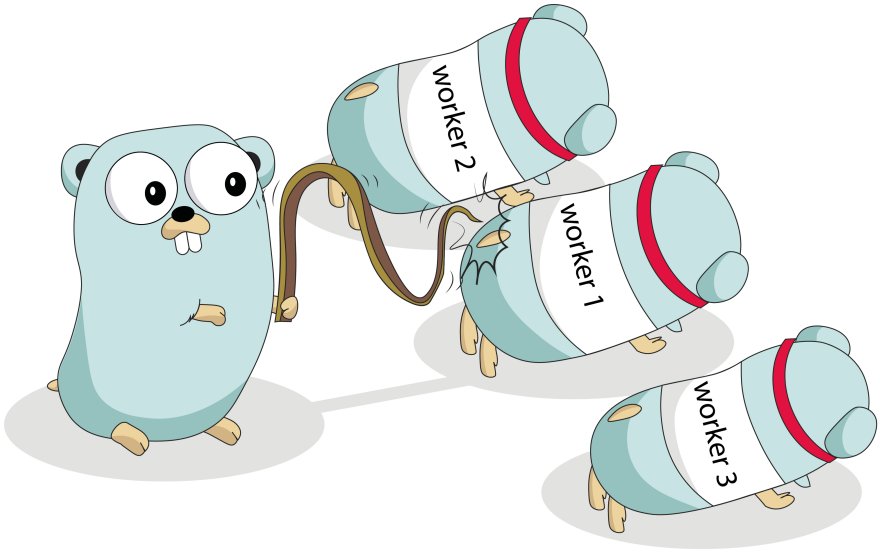

고루틴은 Go 런타임이 관리하는 논리적 (혹은 가상) 경량 쓰레드인데, OS 쓰레드보다 훨씬 가볍게 동시성 처리를 구현하기 위해 만들어졌다.

KCC 말뭉치로부터 생성된 각 문장 벡터들마다 고루틴을 하나씩 생성하고 동시에 입력 문장 벡터와 유사도를 계산하여 채널에 보냄으로써 동시성을 달성한다. (멀티 쓰레딩)

채널 (channel) 은 파이프와 같은 형태의 자료구조로 고루틴 간 통신에 사용된다.

두 벡터 간 유사도를 측정하는 데에도 다양한 방법이 있는데, 이 과제에서는 널리 쓰이는 방법인 코사인 유사도 (cosine similarity) 를 사용했으며 코사인 유사도를 아래와 같이 정의된다.

$$similarity(A,B) = \frac{A \cdot B}{\|A\| \times \|B\|} = \frac{\sum_{i=1}^{n} A_i \times B_i}{\sqrt{\sum_{i=1}^{n} A_i^2} \times \sqrt{\sum_{i=1}^{n} B_i^2}}$$

또한 멀티 쓰레딩과 더불어 논리적 CPU를 모두 계산에 참여시키기 위해 runtime 패키지의 GOMAXPROCS 함수를 호출했다.

- 두 문장 벡터 간 코사인 유사도를 계산하는 함수 Cos

```
// Cos computes the cosine similarity of the given vectors.
func Cos(v, u Vector) float64 {
  return v.dot(u) / (v.norm() * u.norm())
}
```

- goroutine을 이용해 병렬적으로 유사도를 계산하여 채널에 보내는 main의 일부

```
expressions := make(chan vector.Expr, len(sentenceNvectors))

var syncer sync.WaitGroup

syncer.Add(len(sentenceNvectors))

for index := 0; index < len(sentenceNvectors); index++ {
  go func(i int, ch chan vector.Expr) {
    defer syncer.Done()

    expression := vector.NewExpr(originVector, sentenceNvectors[i].vector, sentenceNvectors[i].sentence)
    ch <- expression
  }(index, expressions)
}

defer close(expressions)

syncer.Wait()
```

- runtime.GOMAXPROCS 함수를 호출하여 모든 논리적 CPU를 사용하게 하는 main의 일부

```
runtime.GOMAXPROCS(runtime.NumCPU())
```

5. 채널의 각 문장-유사도 구조체에 접근하여 최대 힙에 push

유사도가 가장 높은 순으로 정렬하는 방법도 있지만, 가장 높은 n개만 뽑아내는 데에는 최대 힙 (max heap) 가장 효율적이다.

최대 힙은 부모 노드가 자식 노드보다 항상 큰 값을 가지는 자료구조로, heap 인터페이스를 달성함으로써 구현할 수 있으며 heap 인터페이스는 Len, Less, Swap, Push, Pop 메소드를 정의함으로써 달성할 수 있다.

- 입력 문장과의 코사인 유사도를 기준으로 최대 힙을 구현한 maxheap.go

```
// MaxHeap is a max heap type.
type MaxHeap []vector.Expr

// Len implements the heap interface.
func (m MaxHeap) Len() int

// Less implements the heap interface.
func (m MaxHeap) Less(i, j int) bool

// Swap implements the heap interface.
func (m MaxHeap) Swap(i, j int)

// Push implements the heap interface.
func (m *MaxHeap) Push(element interface{})

// Pop implements the heap interface.
func (m *MaxHeap) Pop() interface{}
```

- 최대 힙을 생성하고 채널의 구조체를 heap push를 통해 최대 힙에 저장하는 main의 일부

```
maxHeap := maxheap.New()

heap.Init(maxHeap)

for i := 0; i < len(expressions); i++ {

heap.Push(maxHeap, <-expressions)

}
```

6. 최대 힙에서 n번 pop하여 유사도가 높은 문장 출력 및 시간 측정

- 6 을 구현한 main의 일부

```
for i := 0; i < argv; i++ {
  expr := heap.Pop(maxHeap).(vector.Expr)
  fmt.Fprintf(os.Stdout, "%d. %s\n", i+1, expr)
}

elapsedTime := time.Since(startTime)

fmt.Fprintf(os.Stdout, "\nElapsed Time:\t%s\n\n", elapsedTime)
```

타 모델과의 비교 및 결과 분석

(학습 데이터는 모두 KCC 말뭉치로 동일)

- N-gram으로 유사도를 측정한 경우

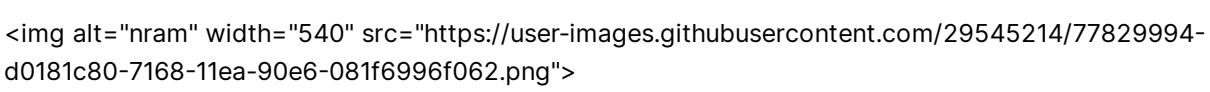

- SPM 모델로 학습시켜 유사도를 측정한 경우 (50000개 문장으로 학습)

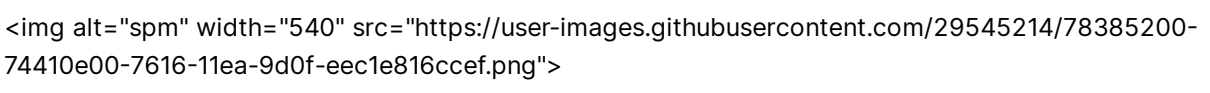

- word2vec 모델로 학습시켜 유사도를 측정한 경우 (2878만개 문장으로 학습)

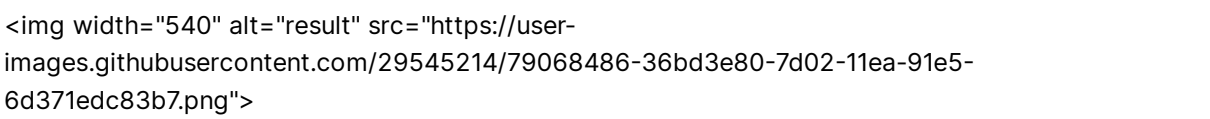

결과 분석

모델 평가

Name	N-gram	SPM	word2vec
유사도 판별 능력	↓	-	↑
처리 시간	↑	↓	↑

N-gram 모델은 학습 데이터 없이 공통 음절/어절의 갯수로만 유사도를 계산하기 때문에 실행 시간은 적게 걸리지만

단순히 공통 음절/어절의 갯수만 세는 방식이므로 의미적으로 유사한 문장을 만들어내기에는 다소 무리가 있어보인다.

SPM 모델은 주어진 데이터로 모델을 학습시켜 유사도를 측정한다는 점에서는 워드 임베딩 방식과 유사하지만 unsupervised tokenizer이기 때문에 처리 속도가 느린 편이고,

공통인 단어 토큰을 세어 유사도를 측정하기 때문에 워드 임베딩 방식에 비해 의미적으로 유사한 문장을 골라내는 능력은 떨어진다.

word2vec 모델은 단어를 벡터로 변환하는 과정에서 단어가 가진 의미를 보존하기 때문에 타 모델보다 의미적으로 더 유사한 문장을 찾아내기에 더 적합하다고 볼 수 있다.

또한 Hierarchical Softmax와 Negative Sampling을 통해 최적화함으로써 처리 시간도 크게 줄어들었다.

멀티 쓰레딩을 통한 시간 단축을 고려하더라도 SPM 모델이 50000개의 문장으로 학습하여 유사도를 측정하는 시간과 word2vec이 2878만개 문장으로 학습하여 유사도를 측정하는 시간의 차이가

1초가 채 되지 않는다는 점에서 word2vec 모델이 성능적으로 더 우수하다고 볼 수 있다.